

2º. Trabalho de EDA – Compactação e descompactação de arquivos texto

Descrição: O algoritmo de Huffman permite comprimir informação sem perda através da recodificação dos seus bytes. O algoritmo consiste de uma série de passos nos quais é possível construir a codificação (fluxo de bits comprimido) que substitui o fluxo de bits original.

O princípio do algoritmo é de gerar códigos mais curtos para caracteres mais frequentes e códigos maiores para os caracteres menos frequentes.

Um primeiro algoritmo de compactação poderia ser implementado da seguinte forma:

Utilizando a tabela ASC para os caracteres maiúsculos e os caracteres “.”, “,”, “;”, “espaço”, “?” e “!” (aqui representado como EOF), trocar caractere a caractere o código ASC estendido, de 8 bits para o correspondente em 5 bits fixos (varia de ‘00000’ a ‘11111’) de acordo com uma tabela onde:

O caractere “A” corresponderia ao código de 5 bits ‘00000’,
O caractere “B” corresponderia ao código de 5 bits ‘00001’,
O caractere “C” corresponderia ao código de 5 bits ‘00010’,
e assim sucessivamente, ...
O caractere “?” corresponderia ao código de 5 bits ‘11110’,
O caractere “fim de arquivo” corresponderia ao código de 5 bits ‘11111’.

Desta forma, este algoritmo de compactação iria ganhar 3 bits para cada caractere de 8 bits, onde um arquivo original de 1K bytes, seria comprimido para 640 bytes.

Assim, o texto “ABRACADABRA!” teria a representação em bits como:

01000001 01000010 01010010 01000001 01000011 01000001 01000100 01000001 01000010 0101
A B R A C A D A B
001001000001 00100001 - totalizando 12 x 8 = 96 bits
R A !

E o arquivo comprimido teria a seguinte representação em bits:
0000000001 10001 00000 00010 00000 00011 00000 00001 100010000011111 - totalizando 60 bits
A B R A C A D A B R A !


Um segundo algoritmo, mais eficiente na compactação, foi proposto por Huffman. Este algoritmo permite comprimir informação, sem perda, também através da recodificação dos seus bytes. O algoritmo consiste de uma série de passos nos quais é possível construir a codificação (fluxo de bits comprimido) que substitui o fluxo de bits original. O princípio do algoritmo é de gerar **códigos mais curtos para caracteres mais frequentes e códigos maiores para os caracteres menos frequentes** (pesquisar sobre árvores Trie ou árvore de prefixos).

De forma geral, o algoritmo consiste em construir um histograma dos caracteres utilizados no texto em ordem de frequência. Vamos supor que o texto seja “ABRACADABRA!” e o histograma indique que a ordem de frequência no texto seja o caractere “A” o mais frequente, em seguida o caractere “B”, depois o “R”, em seguida o “C”, depois o “D” e finalmente o “!” (indicando o EOF). Assim, o histograma seria:

Caractere “A” – ocorre 5 vezes
Caractere “R” – ocorre 2 vezes
Caractere “B” – ocorre 2 vezes
Caractere “D” – ocorre 1 vez
Caractere “!” – ocorre 1 vez
Caractere “C” – ocorre 1 vez

Huffman propôs usar uma árvore de prefixos, onde os prefixos da representação em bits são únicos.

Exemplo da árvore de prefixos e respectiva representação dos caracteres em bits:



Desta forma, a representação interna do arquivo comprimido fica:

0111110010110100011111001010 - totalizando 28 bits
A B RA CA DA B RA !

O trabalho de EDA consiste em **implementar um compactador e um descompactador de arquivos de texto com base no algoritmo de Huffman.**

Para teste do algoritmo, pode ser usado um arquivo contendo a seguinte frase: “AS ESTRUTURAS DE DADOS SÃO FUNDAMENTAIS PARA A ORGANIZACAO E A MANIPULACAO EFICIENTE DAS INFORMACOES”.

Exiba a tabela obtida. Esta saída deve fazer parte do relatório.

Para compactar e descompactar o arquivo implemente uma tabela contendo o caractere e o número de ocorrências do caractere no texto e outra contendo o caractere, o código binário correspondente e o seu tamanho em bits.

Siga as orientações de entrega de laboratórios descrita no EAD.

Atenção: Trabalhos entregues com atraso sofrerão perda de 10% de sua nota por cada dia após o prazo de entrega.

O arquivo a ser compactado e descompactado para verificação da correção do seu programa está no EAD.